

Speech Analysis for Depression Assessment

an Intelligent Signal Analysis project

ANTONIO SPEDITO

*antonio.spedito@community.unipa.it*¹,

ANDREA SPINELLI

*andrea.spinelli@community.unipa.it*¹, and

DAVIDE BONURA

*davide.bonura@community.unipa.it*¹

¹*Computer Science Engineering Department, Università degli Studi di Palermo, Italy*

September 19, 2025

Abstract

La depressione rappresenta una delle principali sfide nel campo della salute mentale, con un impatto significativo sulla qualità della vita. Questo lavoro affronta il problema del rilevamento automatico della depressione dal parlato utilizzando il dataset DAIC-WOZ, con la possibilità di integrare campioni sintetici provenienti da eDAIC come tecnica opzionale di data augmentation per mitigare lo sbilanciamento delle classi. Viene proposta una valutazione comparativa di diversi approcci: una SVM basata su feature acustiche ingegnerizzate (articolazione, fonazione, prosodia), una CNN 1-D che opera direttamente sull'audio grezzo segmentato, e un modello di Self-Supervised Learning che sfrutta wav2vec 2.0 come estrattore di rappresentazioni, combinato con moduli BiLSTM/Transformer e meccanismi di attention pooling per catturare le dipendenze temporali a lungo termine. La pipeline di preprocessing include la separazione del parlato del partecipante, la rimozione dei silenzi e la normalizzazione dei segmenti audio. La validazione è effettuata tramite k-fold cross-validation, con ricerca degli iperparametri ottimali ed early stopping. Il contributo principale di questo lavoro consiste nel fornire una baseline riproducibile e nel valutare sistematicamente il guadagno ottenibile da modelli end-to-end e SSL in un contesto clinico caratterizzato da risorse limitate e dati etichettati scarsi.

Keywords: *Depressione; Analisi del parlato; DAIC-WOZ; eDAIC; Support Vector Machine; CNN 1-D; wav2vec 2.0; Self-supervised learning; Data augmentation; K-fold cross-validation*

Contents

1	Introduzione	3
1.1	Background e Motivazioni	3
1.2	Impatto Clinico e Sociale della Depressione	3
1.3	Limitazioni dei Metodi di Valutazione Tradizionali	4
1.4	Obiettivi e Contributi Principali	4
2	Stato dell'Arte	6
2.1	Approcci Tradizionali	6
2.2	Dataset e Feature Acustiche	7
2.3	Approcci Deep Learning Based	8
2.4	Gap nella Letteratura e Novità	9
2.4.1	Approccio SVM	9
2.4.2	Approccio CNN	9
2.4.3	Approccio SSL	10
3	Metodologia	11
3.1	Support Vector Machine	11
3.2	Convolutional Neural Network	12
3.2.1	TDNN Details	12
3.2.2	CNN-1D Details	12
3.3	Self-Supervised Learning	13
3.3.1	Feature Extractor	13
3.3.2	Architettura Proposta	13
3.3.3	Pooling e Classificazione Finale	14
3.3.4	Strategia Sperimentale	14
4	Risultati	16
4.1	Dataset e Pre-elaborazione	16
4.1.1	Descrizione del Dataset	16
4.1.2	Data Cleaning	16
4.1.3	Data Augmentation e Bilancio delle Classi	17
4.2	Impostazioni Sperimentali	17
4.2.1	Architettura SVM	17
4.2.2	Architettura CNN	18
4.2.3	Architettura SSL	18
4.3	Addestramento dei modelli	18
4.3.1	Modello SVM	18
4.3.2	Modello CNN	19
4.3.3	Modello SLL	19
4.4	Metriche di Valutazione	19
4.5	Confronto con Modelli Esistenti	20
4.6	Disponibilità del codice	23
5	Conclusioni	24
5.1	Interpretazione dei risultati	24
5.2	Implicazioni Etiche e Cliniche	24
5.3	Punti di forza	25
5.4	Limiti e Lavori Futuri	25
6	Bibliografia	26

1 Introduzione

Il Disturbo Depressivo Maggiore (MDD), comunemente noto come depressione, rappresenta una delle più pervasive e invalidanti condizioni mediche a livello globale, con un impatto profondo sulla qualità della vita individuale e un onere significativo per la società [M+12; Cui+24]. Secondo l'Organizzazione Mondiale della Sanità (OMS), la depressione è la principale causa di disabilità nel mondo, affliggendo oltre 300 milioni di persone e posizionandosi come uno dei maggiori contribuenti al carico globale delle malattie [Yan+15; RMT21]. La sua eziologia è multifattoriale e complessa, risultante da una intricata interazione tra predisposizione genetica, fattori ambientali, stress psicologico e alterazioni neurobiologiche [Yan+15; RMT21].

1.1 Background e Motivazioni

Clinicamente, il disturbo è caratterizzato da sintomi cardine quali umore deflesso persistente e anedonia (la perdita di interesse o piacere), ma la sua manifestazione si estende a una costellazione di sintomi cognitivi, emotivi e somatici che compromettono gravemente il funzionamento quotidiano [KZ12; Cor23]. Inoltre, la depressione presenta un'elevata comorbidità con numerose altre patologie, incluse malattie cardiovascolari, diabete, demenza e disturbi neurodegenerativi come il morbo di Parkinson, complicandone la prognosi e aggravando ulteriormente il quadro clinico [Yan+15; Cor23].

Una delle manifestazioni cliniche centrali e oggettivamente osservabili della depressione è il rallentamento psicomotorio [Cor23]. Questo sintomo, che riflette un'alterazione delle funzioni motorie e cognitive mediate da specifici circuiti neurali, si traduce in modo misurabile e diretto in modificazioni della produzione vocale [Cui+24]. La letteratura scientifica ha consistentemente documentato una serie di biomarcatori vocali associati allo stato depressivo. Questi includono una prosodia appiattita (eloquio monotono) con una ridotta variabilità della frequenza fondamentale (F0), una diminuzione della velocità del parlato (speaking rate), un aumento della frequenza e della durata delle pause, una minore energia vocale e alterazioni significative nelle caratteristiche spettrali della voce, come i coefficienti cepstrali in frequenza mel (MFCC) [RMT21; NSA21]. Queste alterazioni vocali non sono casuali, ma sono considerate la manifestazione esterna di una disfunzione nei sistemi neurotrasmettitoriali e nei circuiti cerebrali che regolano l'umore, la motivazione e il controllo motorio [Cui+24; Mon+22].

In questo contesto, la motivazione principale del nostro studio emerge dalla convergenza di due fattori critici: 1) l'inadeguatezza e la soggettività dei metodi diagnostici tradizionali, che si basano in gran parte su questionari di autovalutazione e interviste cliniche, e 2) il potenziale rivoluzionario dell'intelligenza artificiale (AI) per l'analisi di biomarcatori digitali oggettivi [Nic+23;

Zha+24]. L'attuale paradigma diagnostico è messo in discussione per la sua dipendenza da resoconti soggettivi e per le sue basi teoriche non sempre solide, come evidenziato da recenti review critiche [Mon+22; MH22]. Vi è pertanto un'urgente necessità di strumenti di screening e monitoraggio che siano oggettivi, non invasivi, scalabili e a basso costo. Sfruttando la ricchezza informativa contenuta nel segnale vocale, ci proponiamo di sviluppare un sistema di analisi intelligente che, attraverso l'apprendimento automatico, possa fornire una valutazione quantitativa e continua dello stato depressivo. L'obiettivo non è sostituire il clinico, ma fornirgli uno strumento ecologico e data-driven per una diagnosi più tempestiva e un monitoraggio più efficace e personalizzato [LZC23a; Qua+24].

1.2 Impatto Clinico e Sociale della Depressione

L'impatto è profondo e multidimensionale, estendendosi dalla sofferenza individuale a un vasto onere socio-economico. Sul piano clinico, è la principale causa di disabilità a livello globale e uno dei maggiori fattori di rischio per il suicidio [M+12], con un quadro aggravato dall'elevata comorbidità con altre patologie croniche, fisiche e psichiatriche [Cui+24; Cor23].

L'onere socio-economico è altrettanto devastante, articolandosi in costi diretti (trattamenti, ospedalizzazione) e, in misura ancora maggiore, in costi indiretti derivanti dalla perdita di produttività [Nic+23]. Questo fardello, inoltre, non è distribuito uniformemente, ma grava eccessivamente sul sottogruppo di pazienti con depressione ricorrente, che ne sopporta il peso maggiore nel corso della vita [MH22].

A questo si aggiunge l'impatto pervasivo dello stigma, che alimenta miti e percezioni errate (es. debolezza di carattere) e costituisce una formidabile barriera all'accesso alle cure [KZ12]. La paura del giudizio e l'auto-stigmatizzazione generano un ampio "gap terapeutico", per cui una porzione significativa di individui non cerca mai aiuto, aggravando

la sofferenza individuale e amplificando i costi per la collettività [M+12; RMT21].

1.3 Limitazioni dei Metodi di Valutazione Tradizionali

L'attuale gold standard per la diagnosi di depressione si fonda su interviste cliniche (es. basate sul DSM-5) e questionari di autovalutazione (es. PHQ-9, BDI). Sebbene insostituibili nella pratica clinica, questi strumenti presentano limitazioni intrinseche che la tecnologia può aiutare a mitigare [PH23]:

- **Soggettività e Bias di Autovalutazione:** La diagnosi dipende criticamente dall'accuratezza con cui il paziente riporta i propri sintomi. Questa auto-percezione può essere distorta dalla depressione stessa (es. bias di memoria, pessimismo) o da fattori esterni [RMT21].
- **Stigma e Divulgazione Selettiva:** I metodi basati sull'intervista richiedono una divulgazione attiva da parte del paziente. Come discusso, lo stigma impedisce a molti di essere completamente onesti, portando a una sottovalutazione della gravità dei sintomi e, di conseguenza, a diagnosi mancate o tardive [Cor23].
- **Mancanza di Scalabilità e Accessibilità:** Le valutazioni cliniche richiedono tempo e personale altamente qualificato, risorse limitate e spesso concentrate nei centri urbani. Questo crea disparità nell'accesso alle cure, specialmente per le popolazioni rurali o in sistemi sanitari sotto pressione.
- **Natura Episodica ("Snapshot"):** Un colloquio clinico o un questionario forniscono un'istantanea dello stato mentale del paziente in un singolo punto nel tempo. Questo approccio non è in grado di catturare la natura dinamica e fluttuante dei sintomi depressivi, che è invece fondamentale per monitorare la progressione della malattia e la risposta al trattamento [RMT21].

La combinazione di queste limitazioni evidenzia un vuoto critico: la mancanza di strumenti di valutazione oggettivi, passivi e continui. L'analisi intelligente del segnale vocale si candida come una delle soluzioni più promettenti per colmare questo vuoto, offrendo una metodologia complementare per una valutazione più completa, accessibile e oggettiva della depressione [RMT21].

1.4 Obiettivi e Contributi Principali

Questo studio affronta i limiti dei metodi diagnostici tradizionali, progettando e valutando un sistema per il riconoscimento automatico della depressione dalla voce. A tal fine, confrontiamo sistematicamente le prestazioni di diversi modelli di machine learning, da approcci classici fino a un'architettura avanzata.

I contributi specifici di questo lavoro sono:

1. **Stabilire una Baseline Robusta con Machine Learning Classico (SVM):** Il primo contributo consiste nello sviluppare e validare un sistema di classificazione basato su un modello tradizionale, la Support Vector Machine (SVM). Questo sistema utilizzerà un set completo di caratteristiche acustiche "hand-crafted" (ingegnerizzate manualmente), che includono descrittori prosodici (es. statistiche sul pitch e sull'energia), spettrali (es. MFCC) e di qualità della voce (es. jitter, shimmer). Lo scopo è quello di creare una baseline solida e interpretabile, rappresentativa degli approcci che hanno dominato la letteratura fino a pochi anni fa, con cui confrontare i modelli più avanzati.
2. **Valutare il Potere della Rappresentazione Automatica tramite Deep Learning (CNN):** Il secondo contributo esplora il superamento della necessità di ingegneria delle feature manuale. A tal fine, implementiamo un modello di Rete Neurale Convoluzionale (CNN) progettato per operare direttamente sul segnale vocale grezzo (forma d'onda). L'obiettivo è verificare se la CNN possa apprendere autonomamente le caratteristiche vocali discriminanti per la depressione, catturando pattern locali e texture spettrali che potrebbero sfuggire alle feature predefinite, e potenzialmente migliorando le performance rispetto alla baseline SVM.
3. **Proporre un Modello di Frontiera per Dati Scarsi (Modello SSL Gerarchico):** Il contributo più innovativo di questo paper è la proposta di un modello gerarchico basato su Self-Supervised Learning (SSL). Questo approccio è specificamente motivato da una delle sfide più critiche nel campo medicale: la scarsità di dati etichettati.
 - *Self-Supervised Learning (SSL):* Il modello viene pre-addestrato su vaste quantità di dati vocali non etichettati per apprendere rappresentazioni ricche e generalizzabili del parlato umano.

- *Architettura Gerarchica*: Il modello è progettato per catturare le manifestazioni della depressione a diverse scale temporali: dai micro-fenomeni a livello fonetico (catturati dai layer più bassi) fino ai pattern prosodici a lungo termine che caratterizzano la fraseologia e l'eloquio complessivo (catturati dai layer più alti). Parte integrante di questo contributo è un'analisi sistematica delle performance al variare del layer di estrazione delle feature, al fine di identificare quali livelli di astrazione del parlato siano più informativi per il task di rilevamento della depressione.

2 Stato dell'Arte

Questo capitolo analizza la letteratura sul rilevamento della depressione nel parlato, tracciando la sua evoluzione metodologica del campo. Si parte dagli approcci classici basati sui classificatori e feature ingegnerizzate, per passare ai modelli di deep learning supervisionato (CNN), fino a raggiungere la frontiera attuale rappresentata dai foundation models basati su Self-Supervised Learning (SSL). Per ciascuna di queste tappe evolutive, l'analisi identifica criticamente i gap di ricerca che motivano e giustificano le proposte innovative di questo studio.

2.1 Approcci Tradizionali

Gli approcci che hanno storicamente dominato la ricerca nel rilevamento automatico della depressione, e che ancora oggi costituiscono una solida baseline per il confronto, si basano su un paradigma a due stadi: l'estrazione di caratteristiche ingegnerizzate manualmente (hand-crafted features) e la successiva classificazione tramite un modello di machine learning classico. Come evidenziato da Nickson et al. (2023), questo approccio convenzionale è stato il fondamento per molti sistemi di analisi paralinguistica applicata alla salute.

Il primo stadio del processo consiste nell'estrarre dal segnale vocale un insieme predefinito di descrittori acustici, ritenuti correlati ai sintomi della depressione. La letteratura, inclusa quella citata nel paper di riferimento, converge su un set di feature che include tipicamente caratteristiche prosodiche (pitch, energia), spettrali (formanti), di qualità della voce (jitter, shimmer) e legate al ritmo (tassi di parlato). Nello specifico, il sistema di baseline della challenge AVEC-2016, a cui il paper fa riferimento [Mic+16], utilizzava un vasto insieme di feature estratte tramite il toolbox COVAREP. Questo set includeva, tra gli altri, la frequenza fondamentale (F0), le formanti, il quoziente di ampiezza normalizzato (NAQ) e 24 Mel-Frequency Cepstral Coefficients (MFCC), costituendo un esempio rappresentativo di un set di feature a bassa dimensionalità (low-level descriptors) di alta qualità.

Il secondo stadio impiega queste feature estratte per addestrare un classificatore. Tra i vari algoritmi, nella letteratura e nel tempo, si evince che:

- la **Regressione Logistica (LR)** rappresenta il modello più archetipico e diffuso. Come confermato dalla review di Nickson et al. (2023) [Nic+23], dove risulta il metodo più comune per l'analisi di dati EHR, la sua adozione è motivata da un equilibrio tra semplicità computazionale e, soprattutto, interpretabilità. In un contesto clinico, il suo punto di forza risiede nella capacità di fornire una lettura diretta dell'impatto dei singoli predittori attraverso gli odds ratio. Applicato al dominio del parlato, questo modello verrebbe ali-

mentato da un vettore di feature acustiche predefinite (es. eGeMAPS) per stimare la probabilità di una diagnosi di depressione.

La principale debolezza della LR, che ne costituisce anche un limite strutturale, è la sua assunzione di linearità. Questo modello presuppone che le complesse manifestazioni vocali della depressione possano essere catturate da una combinazione lineare di feature, un'ipotesi difficilmente sostenibile. Il modello è intrinsecamente incapace di catturare le interazioni non lineari e le dipendenze complesse che quasi certamente esistono tra i vari parametri vocali. Essendo inoltre completamente agnostico rispetto al segnale originale, la sua efficacia è vincolata e limitata a priori dalla rappresentazione dei dati che gli viene fornita. Questa lacuna concettuale ha spinto la comunità scientifica a esplorare algoritmi capaci di modellare la non-linearità intrinseca dei dati comportamentali.

- la **Random Forest (RF)**, rispetto ai modelli lineari, fa un salto di qualità. Citato come il secondo modello più popolare per l'analisi degli EHR, il suo meccanismo si basa sulla "saggezza della folla" (ensemble learning) [Nic+23]. Costruendo una moltitudine di alberi decisionali su sottoinsiemi casuali dei dati e delle feature, il RF è in grado di modellare interazioni complesse e non lineari, superando il principale limite della LR. La sua robustezza all'overfitting e la capacità di fornire un ranking di importanza delle feature lo rendono uno strumento prezioso non solo per la classificazione ma anche per l'analisi esplorativa, permettendo di identificare quali biomarcatori acustici risultano più discriminanti. Nonostante la sua potenza nel gestire relazioni non lineari, il potenziale di un Random Forest rimane ingabbiato entro i confini delle feature ingegnerizzate. Anche questo modello, per quanto sofisticato, è dipendente dalla fase di estrazione iniziale e non può scoprire nuovi pattern latenti nel segnale vocale. La sua conoscenza del problema è limitata a ciò che le feature predefinite gli consentono di "vedere". Questo pone un "sof-

fitto di cristallo" invalicabile sulle sue performance. Sebbene rappresenti un'evoluzione cruciale rispetto ai modelli lineari, condivide con essi il gap fondamentale di non poter apprendere direttamente dai dati, una barriera che solo le architetture end-to-end possono abbattere.

- Al vertice degli algoritmi per dati strutturati si collocano i modelli di **gradient boosting**, di cui XGBoost è l'implementazione più nota e, in molti contesti competitivi, più performante. La sua popolarità è confermata anche dalla review di Nickson et al., che lo include tra i metodi più utilizzati per l'analisi dei dati EHR. A differenza di un Random Forest, che addestra alberi in parallelo, XGBoost adotta una strategia sequenziale in cui ogni nuovo albero viene costruito per correggere gli errori dei precedenti. Questo processo iterativo di "affinamento" permette di creare modelli predittivi di altissima precisione.

L'analisi di un modello come XGBoost è fondamentale perché permette di evidenziare il limite ultimo e invalicabile della pipeline tradizionale. Se anche si impiega un classificatore considerato lo stato dell'arte per i dati tabulari, capace di vincere innumerevoli competizioni di data science, la sua efficacia rimane inevitabilmente vincolata alla qualità delle feature estratte a monte. Il vero collo di bottiglia del sistema non è più la potenza dell'algoritmo di classificazione, ma la rappresentazione dei dati che gli viene fornita. Nessun miglioramento, per quanto sofisticato, sul classificatore può compensare l'informazione persa durante la riduzione del segnale vocale a un set statico di feature. Questo gap definitivo dimostra che per un vero salto di qualità è necessario abbandonare il paradigma a due fasi e adottare architetture (come CNN e modelli SSL) che apprendono la rappresentazione come parte integrante del modello.

- la **Support Vector Machine (SVM)** si è affermata come uno dei modelli più utilizzati ed efficaci per questo compito. La sua popolarità deriva dalla sua capacità di gestire spazi di feature ad alta dimensionalità e dalla sua robustezza, specialmente in scenari con dataset di dimensioni contenute, una condizione comune negli studi clinici. Non a caso, il sistema di baseline della challenge AVEC-2016 era basato su un classificatore SVM [Mic+16]. Tuttavia, questo approccio presenta una limitazione fondamentale: la sua performance è intrinsecamente vincolata dalla qualità e dalla completezza del set di feature pre-selezionato. Questo limite è chiaramente

illustrato dai risultati della baseline ufficiale della challenge, riportati da Valstar et al. [Mic+16]. Come mostrato nella Tabella 3 del loro lavoro, il modello basato sui soli dati audio ha ottenuto sul **test set** un F1-score di appena **0.410** per la classe depressa. L'origine di questa performance modesta è rivelata da un'analisi più approfondita delle metriche: il modello raggiungeva una Recall estremamente alta (**0.889**), ma al costo di una Precisione drammaticamente bassa (**0.267**). In termini pratici, questo significa che, sebbene il sistema fosse in grado di identificare quasi il 89% dei partecipanti depressi, lo faceva classificando erroneamente un numero molto elevato di individui sani come depressi, rendendolo di fatto inaffidabile per un'applicazione clinica di screening.

Questa dipendenza dall'ingegneria delle feature e le performance sub-ottimali hanno spinto la comunità scientifica a esplorare approcci di deep learning end-to-end, in grado di apprendere le rappresentazioni discriminanti direttamente dai dati grezzi o da rappresentazioni a basso livello come gli spettrogrammi. Questo passaggio metodologico, motivato proprio dai limiti dei sistemi basati su SVM, costituisce il passo successivo nell'evoluzione di questo campo di ricerca.

2.2 Dataset e Feature Acustiche

La validità e la comparabilità dei risultati nella ricerca sul rilevamento automatico della depressione dipendono criticamente dall'utilizzo di dataset pubblici e standardizzati. Questi corpus forniscono un terreno comune su cui diversi sistemi possono essere valutati secondo protocolli sperimentali condivisi. In questo contesto, il DAIC-WOZ (Distress Analysis Interview Corpus - Wizard-of-Oz) è di particolare rilevanza per la comunità scientifica e per il presente studio.

- **DAIC-WOZ (Distress Analysis Interview Corpus - Wizard-of-Oz)**: Questo corpus in lingua inglese è diventato il benchmark de-facto per il rilevamento della depressione, come descritto e utilizzato in numerosi studi. Esso consiste in una serie di interviste cliniche semi-strutturate condotte da un agente virtuale animato ("Ellie"), che è segretamente controllato da un operatore umano. Il corpus contiene registrazioni audio-video, trascrizioni e, crucialmente, i punteggi di depressione di ogni partecipante misurati tramite il questionario PHQ-8. La classificazione binaria

(depresso vs. non depresso) viene tipicamente eseguita utilizzando una soglia standard sul punteggio PHQ-8 (es. ≥ 10), come seguito nel protocollo della challenge AVEC-2016 [Mic+16].

- **eDAIC (Extended Distress Analysis Interview Corpus):** È fondamentale chiarire che l'eDAIC non è un corpus di nuove registrazioni, bensì un'estensione che arricchisce il DAIC-WOZ esistente con annotazioni più granulari. La sua innovazione principale risiede nell'aggiunta di etichette di depressione a livello di "turno" di parola (turn-level). Mentre il DAIC-WOZ fornisce un unico punteggio di depressione per l'intera intervista, l'eDAIC offre una valutazione della gravità della depressione per ogni singola risposta del partecipante. Questo livello di dettaglio è estremamente prezioso per studiare la dinamica dei sintomi vocali durante l'intervista e per sviluppare modelli capaci di monitorare le fluttuazioni dello stato affettivo, anziché limitarsi a una classificazione complessiva a posteriori.

Per l'estrazione di caratteristiche acustiche da questi dataset, la letteratura fa riferimento a due principali set di feature standardizzati:

1. **Feature COVAREP:** Utilizzato per creare la baseline ufficiale della challenge AVEC-2016, il toolbox COVAREP estrae un insieme completo di descrittori acustici, inclusi frequenza fondamentale, formanti, MFCC e misure di qualità della voce.
2. **eGeMAPS (extended Geneva Minimalistic Acoustic Parameter Set):** Un set standard di 88 caratteristiche acustiche, selezionate per la loro rilevanza nell'analisi delle emozioni e della paralinguistica. Include statistiche su pitch, loudness, formanti, MFCC, jitter e shimmer. Il suo carattere "minimalista ma completo" lo rende una scelta ideale per baseline robuste.

Per il nostro approccio di machine learning classico (baseline SVM), utilizzeremo il set di feature standardizzato di Disvoice. Questa scelta assicura che i nostri risultati siano riproducibili, facilmente confrontabili con lo stato dell'arte e fondati su un insieme di biomarcatori vocali consolidato e teoricamente motivato.

2.3 Approcci Deep Learning Based

Con l'aumento della potenza computazionale e la necessità di superare i limiti dell'ingegneria manuale delle feature, la ricerca si è orientata verso modelli

di deep learning. L'idea fondamentale è quella di fornire al modello una rappresentazione del segnale più grezza, come uno spettrogramma, e lasciare che sia la rete neurale stessa ad apprendere le caratteristiche discriminanti.

Le Reti Neurali Convoluzionali (CNN), originariamente sviluppate per l'analisi di immagini, si sono dimostrate particolarmente adatte a questo compito. Trattando direttamente lo spettrogramma (o un log-spettrogramma), oppure i frame temporali dell'audio, le CNN possono apprendere gerarchie di pattern, dai bordi e texture locali (corrispondenti a fenomeni fonetici e armonici) a strutture più complesse.

Un esempio emblematico di questo approccio è lo studio di Wang et al. [JVA23] che affronta la rilevazione della depressione direttamente dai campioni audio grezzi usando CNN-1D e TDNN. Gli autori sottolineano una questione critica: molte metodologie basate su embedding del parlante incorporano inevitabilmente informazioni di identità, creando problemi di privacy e potenziali distorsioni. Per superare questo limite, propongono un meccanismo di *Non-Uniform Speaker Disentanglement* (NUSD), che applica la penalizzazione avversaria in modo differenziato tra i livelli di estrazione delle feature e quelli di processamento. In questo modo il modello impara a sopprimere precocemente le tracce di identità del parlante, mantenendo però intatte le informazioni utili alla classificazione dello stato depressivo.

Il loro lavoro dimostra chiaramente la superiorità di questo approccio rispetto a metodi classici e anche rispetto a disentanglement uniforme. Sul dataset DAIC-WOZ, la variante ECAPA-TDNN con NUSD raggiunge un F1-score di **0.7349**, migliorando del 3.7% rispetto alla versione standard e riducendo contemporaneamente l'accuratezza di speaker identification di circa il **50%**. Questi risultati evidenziano come l'uso diretto del raw audio, combinato a un disentanglement stratificato, consenta di ottenere modelli allo stesso tempo più accurati e più rispettosi della privacy.

Sebbene questo approccio abbia dimostrato risultati promettenti, rimane un limite ben noto e richiamato dagli stessi autori: la *scarsità di dati etichettati* in ambito clinico. Addestrare da zero modelli complessi di deep learning su raw audio richiede infatti corpora ampi e bilanciati, che nella pratica sono difficili e costosi da raccogliere.

La soluzione più moderna a questa sfida è il Self-Supervised Learning (SSL), incarnato da modelli pre-addestrati su larga scala. L'idea è di sfruttare migliaia di ore di parlato non etichettato per ad-

destrare un modello—come HuBERT o wav2vec 2.0—a comprendere le rappresentazioni fondamentali del linguaggio umano [WCC23; Góm+25]. Questo potente modello "pre-addestrato" viene poi specializzato per il task specifico (es. rilevamento della depressione) tramite un processo di *fine-tuning* su un dataset etichettato molto più piccolo, come il DAIC-WOZ.

Gli studi di Wu et al. [WCC23] e Gómez-Zaragozá et al. [Góm+25] rappresentano lo stato dell'arte di questo paradigma. Le loro architetture, sebbene differenti nei dettagli, seguono un approccio gerarchico comune ed efficace:

1. **Feature Extractor:** Utilizzano un *foundation model* (come HuBERT o WavLM) per estrarre feature ad alto livello direttamente dal segnale audio grezzo. Questo approccio sostituisce completamente gli spettrogrammi e le feature ingegnerizzate manualmente, catturando sfumature acustiche e linguistiche molto più complesse.
2. **Codifica Sequenziale:** Le feature estratte dal modello pre-addestrato vengono processate da una rete sequenziale, come un'unità GRU (Gated Recurrent Unit) [Góm+25] o un blocco Transformer [WCC23]. Questo secondo stadio ha il compito di modellare le dipendenze temporali a lungo termine tra i vari segmenti di parlato dell'intera intervista, apprendendo i pattern dinamici associati alla depressione.
3. **Classificazione Finale:** Per arrivare a una singola diagnosi per l'intero paziente, le strategie finali divergono pur essendo entrambe efficaci. Gómez-Zaragozá et al. adottano un approccio aggregativo, classificando prima finestre di segmenti (ogni segmento ottenuto dalle trascrizioni in questo caso) sovrapposte per poi aggregare i risultati delle finestre che compongono l'intero audio tramite un *majority voting*. Al contrario, Wu et al. impiegano un approccio olistico in cui il modello Transformer processa l'intera sequenza di un'intervista per generare un'unica predizione finale, senza passaggi di voto intermedi sui segmenti.

Una scoperta cruciale, evidenziata in entrambi gli studi, è che le performance migliorano ulteriormente se i modelli di base vengono pre-specializzati (*fine-tuned*) su task correlati come il riconoscimento delle emozioni (Emotion Recognition, ER), dimostrando un trasferimento di conoscenza efficace tra i due domini. Questo approccio fa passare l'F1-score da 70% a un 72% come mostrato nella tabella 1 di [WCC23].

2.4 Gap nella Letteratura e Novità

Nonostante i notevoli progressi, un'analisi critica della letteratura esistente rivela diverse domande aperte e aree di miglioramento non ancora esplorate. Questi "gap" costituiscono la base di partenza e la giustificazione per la nostra ricerca.

2.4.1 Approccio SVM

Per colmare il gap di una valutazione comparativa rigorosa, la nostra prima proposta si concentra sulla riproduzione di una baseline SVM con un approccio alternativo. Invece di limitarci a set di feature generici e ampiamente utilizzati come eGeMAPS o COVAREP, la nostra proposta si ispira al lavoro di Narendra et al. (2021) nel campo del rilevamento del morbo di Parkinson (PD) da segnali vocali.

La logica di questo trasferimento concettuale risiede nel fatto che, sebbene le eziologie siano diverse, sia il Parkinson (un disturbo del movimento) che la depressione (attraverso il rallentamento psicomotorio) si manifestano con alterazioni vocali, che includono deficit nella fonazione, nell'articolazione e nella prosodia. Narendra et al. dimostrano l'efficacia non solo di un set di feature di base che copre queste tre aree, ma soprattutto di caratteristiche glottali estratte tramite Glottal Inverse Filtering (GIF), che descrivono direttamente la sorgente della voce, un'informazione fondamentale spesso trascurata nelle analisi standard [NSA21].

Tuttavia, un'implementazione diretta non è possibile e rappresenta la sfida centrale che la nostra proposta affronta. Il lavoro di Narendra et al. si basa sul dataset PC-GITA, che contiene registrazioni di task vocali brevi e strutturati (es. fonazioni sostenute, esercizi diadochocinetici, lettura di parole). Al contrario, il nostro studio utilizza il dataset DAIC-WOZ, caratterizzato da interviste cliniche lunghe, spontanee e non strutturate.

La novità del nostro approccio SVM consiste quindi nell'adattare e generalizzare questo ricco set di feature, originariamente pensato per audio brevi, al dominio del parlato conversazionale. Nello specifico, la nostra metodologia prevede di estrarre le feature di tipo articolatorio, fonatorio e prosodico (ispirate da Narendra et al.) applicate alle intere interviste di DAIC-WOZ.

2.4.2 Approccio CNN

Per affrontare il gap di una valutazione sistematica, la nostra seconda proposta introduce un modello CNN supervisionato che agisce da ponte

tra gli approcci classici e quelli di frontiera. Invece di progettare un'architettura completamente nuova, la nostra novità risiede nell'adattamento cross-patologico e cross-dominio di un modello di deep learning end-to-end la cui efficacia è già stata dimostrata in un contesto simile.

Nello specifico, ci ispiriamo all'architettura end-to-end proposta da Narendra et al. per il rilevamento del Parkinson. Il loro modello, una combinazione di layer convoluzionali seguiti da un multilayer perceptron (CNN+MLP), è progettato per operare direttamente su forme d'onda grezze (raw waveforms). La nostra novità risiede nell'adattamento dell'architettura al diverso dominio temporale del dato. Mentre il modello originale di [NSA21] è stato progettato per analizzare frame molto brevi (circa 250 ms), tipici di task vocali strutturati, il nostro obiettivo è catturare pattern prosodici e dinamiche del parlato che si manifestano su scale temporali più lunghe, caratteristiche del discorso spontaneo in DAIC-WOZ. Pertanto, la nostra innovazione metodologica consiste nel segmentare il segnale audio in finestre significativamente più lunghe (es. 3-5 secondi) con un certo grado di sovrapposizione. La durata ottimale di questi segmenti non è definita a priori, ma viene determinata empiricamente attraverso la validazione incrociata, permettendo al modello di apprendere le feature più discriminanti alla scala temporale più adatta per il rilevamento della depressione.

2.4.3 Approccio SSL

La nostra proposta più significativa si colloca nella frontiera della ricerca, dove l'obiettivo non è solo massimizzare le performance, ma anche sviluppare architetture capaci di gestire efficacemente la natura estesa e gerarchica del parlato clinico. Partendo dall'impiego consolidato dei Foundation Models (es. WavLM, HuBERT) come potenti estrattori di feature [Qua+24], la nostra novità si concentra sulla

strategia di processamento a valle di queste rappresentazioni.

Molti approcci esistenti processano i singoli segmenti vocali in modo indipendente o li concatenano in sequenze molto lunghe, ponendo sfide computazionali e di modellazione. La nostra innovazione metodologica introduce una **strategia di segmentazione e raggruppamento (chunking) a due livelli** per analizzare le interviste.

1. **Segmentazione Primaria:** In primo luogo, l'intera intervista di un partecipante viene suddivisa in segmenti audio di media durata (es. 10 secondi). Basandoci sulle evidenze emerse dalla validazione del modello CNN, utilizziamo la segmentazione guidata dalla trascrizione, che si è dimostrata più efficace nel catturare unità di discorso significative.
2. **Chunking Contestuale:** Successivamente, questi segmenti non vengono processati individualmente, ma raggruppati in "chunk" sovrapposti di dimensione variabile (es. 5, 10 o 15 segmenti per chunk). Questi chunk vengono quindi forniti come input al modello sequenziale (es. BiLSTM o Transformer).

Il razionale di questo approccio è duplice: da un lato, permette di fornire al modello un contesto temporale più ampio rispetto a un singolo segmento; dall'altro, mantiene la sequenza di input a una lunghezza gestibile. I parametri chiave di questa strategia — la dimensione dei chunk e il grado di sovrapposizione — sono trattati come iperparametri e ottimizzati tramite cross-validation.

Infine, per ottenere una singola predizione per l'intero partecipante, il modello classifica ogni chunk in modo indipendente e i risultati vengono aggregati tramite una strategia di **majority voting**. Questo approccio robusto simula una valutazione complessiva basata su molteplici "ascolti" contestualizzati di porzioni diverse dell'intervista.

3 Metodologia

Questo capitolo descrive il quadro metodologico adottato per il rilevamento della depressione, strutturato in un'analisi comparativa di tre approcci con complessità crescente. Inizieremo con la nostra baseline, un modello classico basato su Support Vector Machine (SVM) e feature acustiche ingegnerizzate. Proseguiremo descrivendo un modello di deep learning end-to-end, che impiega una Rete Neurale Convoluzionale (CNN) 1D per apprendere direttamente dalla forma d'onda del segnale audio. Infine, presenteremo il nostro modello di frontiera basato su Self-Supervised Learning (SSL), che utilizza un foundation model pre-addestrato come estrattore di feature, seguito da un modulo di codifica sequenziale (BiLSTM o Transformer) per modellare le dipendenze temporali a lungo termine. Per ogni approccio verranno discussi i principi teorici e l'architettura implementata.

3.1 Support Vector Machine

Il nostro primo modello si basa su un approccio tradizionale a pipeline, che prevede due stadi distinti: l'estrazione di un set di feature acustiche ingegnerizzate manualmente dal segnale vocale e la successiva classificazione tramite una Support Vector Machine (SVM). Questa metodologia è stata scelta per stabilire una baseline robusta e interpretabile, rappresentativa degli approcci consolidati in letteratura.

La Support-Vector Machine (SVM), introdotta da Cortes e Vapnik (1995) [CV95], è un classificatore binario supervisionato il cui obiettivo è trovare l'iperpiano ottimale che massimizza il margine tra i campioni delle due classi. Dato un set di training di l campioni etichettati (x_i, y_i) dove $x_i \in \mathbb{R}^n$ è il vettore delle feature e $y_i \in \{-1, 1\}$ è l'etichetta della classe, l'SVM cerca un iperpiano definito da:

$$\mathbf{w} \cdot \mathbf{x} - b = 0$$

dove w è il vettore normale all'iperpiano e b è il bias. L'iperpiano "ottimale" è quello che massimizza la distanza tra gli iperpiani paralleli più vicini a ciascuna delle due classi, noti come iperpiani di margine. La distanza tra questi due iperpiani è $2/\|\mathbf{w}\|$. Massimizzare il margine equivale quindi a minimizzare $\|\mathbf{w}\|^2$ [CV95].

Questo problema di ottimizzazione vincolata, per il caso linearmente separabile, può essere formulato come:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \text{ soggetto a}$$

$$y_i(\mathbf{w} \cdot \mathbf{x}_i - b) \geq 1, \quad i = 1, \dots, l$$

I campioni che giacciono sugli iperpiani di margine sono chiamati vettori di supporto (support vectors), poiché sono gli unici a determinare la posizione e l'orientamento dell'iperpiano di separazione.

Nella maggior parte dei problemi reali, i dati non sono linearmente separabili nello spazio di in-

put originale. Le SVM affrontano questa sfida proiettando i dati in uno spazio delle feature a dimensionalità molto più elevata, dove è più probabile che esista un iperpiano separatore. Questo viene realizzato attraverso una funzione di mappatura non-lineare $\phi(x)$. L'idea geniale, nota come kernel trick, è che non è necessario calcolare esplicitamente la trasformazione $\phi(x)$, che sarebbe computazionalmente proibitiva. È sufficiente definire una funzione kernel $K(x_i, x_j)$ che calcola il prodotto scalare tra le trasformazioni dei vettori $\phi(x) \cdot K(x_i, x_j)$ [CV95]. La funzione di decisione diventa quindi:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^l \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) - b \right)$$

dove le α_i sono i moltiplicatori di Lagrange ottenuti risolvendo il problema duale, e sono diversi da zero solo per i vettori di supporto.

La scelta della funzione kernel è cruciale e determina la forma della superficie di decisione. Per il nostro studio, abbiamo scelto il kernel Radial Basis Function (RBF), una scelta standard e molto efficace per problemi complessi e non lineari:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

L'efficacia di un classificatore SVM con kernel RBF è governata da due iperparametri principali:

- C (parametro di regolarizzazione): Controlla il trade-off tra la massimizzazione del margine e la minimizzazione dell'errore di classificazione sui dati di training.
- γ (gamma): Definisce l'influenza di un singolo campione di training.

La selezione ottimale di C e γ verrà eseguita tramite una grid search con validazione incrociata sul nostro set di training.

3.2 Convolutional Neural Network

Il nostro secondo approccio metodologico supera i limiti della pipeline tradizionale, adottando un modello di deep learning capace di apprendere le feature discriminanti direttamente da una rappresentazione a basso livello del segnale. Nello specifico, la nostra proposta si basa sull'uso di architetture convoluzionali che operano su rappresentazioni temporali del parlato. Questo approccio end-to-end mira a catturare pattern locali che potrebbero sfuggire alle feature ingegnerizzate.

Per fornire il segnale vocale alla rete, utilizziamo direttamente la forma d'onda, preventivamente campionata, e una CNN monodimensionale (1-D). Il segnale è preventivamente uniformato in frequenza di campionamento e normalizzato (rimozione della componente DC e standardizzazione), quindi suddiviso in segmenti temporali di lunghezza fissata. Ogni segmento è processato da strati convolutivi 1-D lungo l'asse temporale, con kernel dell'ordine di pochi millisecondi e stride controllato, eventualmente accompagnati da dilatazioni e operazioni di pooling per ampliare il campo recettivo fino a catturare dipendenze di più lungo periodo.

3.2.1 TDNN Details

Le Time Delay Neural Networks (TDNN), introdotte da Waibel et al. (1989) [Wai+89], sono state una delle prime architetture convoluzionali progettate specificamente per segnali sequenziali come il parlato. L'idea fondamentale è di ottenere invarianza rispetto a traslazioni temporali. Una TDNN è costituita da unità che esaminano non solo l'input al tempo t , ma anche un contesto temporale. Una singola unità TDNN in un layer nascosto calcola il suo output h_t al tempo t come:

$$h_t = f \left(b + \sum_{i=0}^N \mathbf{w}_i \cdot \mathbf{x}_{t-i} \right)$$

dove $\mathbf{x}_{t-i}$ è il vettore di input al tempo $t-i$, $\mathbf{w}_i$ è il vettore dei pesi associato al ritardo i , N è la dimensione della finestra temporale, b è un bias e f è una funzione di attivazione non lineare (es. sigmoide). Concettualmente, questo equivale ad applicare un filtro convoluzionale 1D lungo l'asse temporale dell'input. Un aspetto cruciale è che i pesi del filtro ($w_0, \dots, w_N$) sono condivisi (shared) per tutte le posizioni temporali t , permettendo al modello di apprendere a riconoscere un pattern acustico indipendentemente da quando esso appare nella sequenza. Le architetture TDNN impilano più layer di questo tipo, dove i layer superiori apprendono a

riconoscere pattern temporali più lunghi e astratti basandosi sugli output dei layer inferiori [Wai+89].

3.2.2 CNN-1D Details

L'approccio TDNN si è evoluto nelle moderne CNN per l'analisi di sequenze, come descritto in lavori seminali quali Lecuna et al. (1998) [Lec+98] e adattato a compiti di classificazione di testo da Kim (2014) [Kim14]. Sebbene concettualmente simili alle TDNN, queste architetture vengono spesso descritte in modo più generale. Nel nostro caso, la 1D-CNN opera su un frame temporale di lunghezza fissa.

Sia $X \in \mathbb{R}^{n \times d}$ la matrice di input, dove n è il numero di frame temporali e d è il numero di canali audio (o la dimensione dell'embedding). Una convoluzione 1D applica un filtro (o kernel) $w \in \mathbb{R}^{h \times d}$, dove h è l'altezza del filtro (il numero di frame temporali che "vede" contemporaneamente). Il filtro viene fatto scorrere lungo la dimensione temporale per produrre una feature map $c \in \mathbb{R}^{n-h+1}$. Ogni elemento c_i di questa mappa è generato come:

$$c_i = f(\mathbf{w} \cdot \mathbf{X}_{i:i+h-1} + b)$$

dove $\mathbf{X}_{i:i+h-1}$ è la sotto-matrice (finestra) di X dal frame i al frame $i+h-1$, f è una funzione di attivazione non lineare (comunemente ReLU, Rectified Linear Unit), e b è un termine di bias.

Dopo il passaggio attraverso i blocchi convoluzionali, che estraggono una sequenza di feature map ad alto livello, è necessario aggregare queste informazioni in un unico vettore a dimensione fissa prima della classificazione. A tal fine, invece del max-pooling, la nostra architettura impiega un layer di **Global Average Pooling (GAP)**. Questa operazione calcola la media di ogni feature map lungo la dimensione temporale:

$$\hat{c}_k = \frac{1}{T'} \sum_{t=1}^{T'} c_{k,t}$$

dove c_k è la k -esima feature map di lunghezza T' . Il risultato è un singolo valore per ogni feature map, formando un vettore che riassume le caratteristiche globali del segmento audio. Questo vettore viene poi dato in input a uno o più layer fully-connected (MLP) per la classificazione finale. L'uso del GAP è noto per ridurre l'overfitting e migliorare la robustezza del modello alle traslazioni temporali dei pattern. L'intera architettura viene addestrata end-to-end tramite backpropagation.

3.3 Self-Supervised Learning

Per superare i limiti intrinseci degli approcci supervisionati, legati alla necessità di grandi quantità di dati etichettati, il nostro terzo e più avanzato modello si basa sul paradigma del Self-Supervised Learning (SSL). La nostra proposta adotta un'architettura gerarchica che sfrutta la potenza di un foundation model pre-addestrato per estrarre rappresentazioni vocali ricche, che vengono poi processate da un modulo sequenziale per catturare le dinamiche temporali della depressione.

3.3.1 Feature Extractor

Il primo stadio del nostro modello utilizza un foundation model pre-addestrato per trasformare il segnale audio grezzo in una sequenza di embedding di alta qualità. Per garantire una valutazione completa e robusta, abbiamo selezionato quattro dei più influenti e performanti modelli SSL per il parlato, provenienti da diversi laboratori di ricerca e basati su differenti strategie di pre-addestramento: **Wav2Vec2.0** [Ale+20], **HuBERT** [Hsu+21], **WavLM** [Che+22], e l'encoder di **Whisper** [Rad+22].

Per illustrare il principio di funzionamento di questi modelli, descriveremo in dettaglio l'architettura di Wav2vec 2.0, che funge da esempio prototipico per questo paradigma.

L'architettura, durante l'inferenza, si articola in due componenti principali:

1. **Feature Encoder (CNN)**: Un modulo di layer convoluzionali 1D processa la forma d'onda grezza per estrarre una sequenza di rappresentazioni latenti locali $\mathcal{Z}$.
2. **Transformer (Encoder Contestuale)**: Queste rappresentazioni $\mathcal{Z}$ vengono date in input a un'architettura Transformer, che grazie al meccanismo di self-attention genera le rappresentazioni contestualizzate finali $\mathcal{C}$.

Questo processo permette al modello di apprendere una conoscenza profonda della struttura del parlato umano. Nel nostro approccio, utilizziamo i pesi del modello pre-addestrato (in modalità "frozen", senza ulteriore addestramento) come un potente estrattore di feature, ottenendo una sequenza di vettori $\mathcal{C}$ per ogni segmento audio.

3.3.2 Architettura Proposta

La sequenza di embedding estratta da Wav2vec 2.0 viene processata da un secondo stadio, progettato

per modellare le dipendenze temporali a lungo termine tra i vari "chunk" di segmenti, come descritto nel Capitolo 2. Per valutare quale architettura sia più adatta a questo compito, abbiamo implementato e confrontato due diversi moduli sequenziali: un **BiLSTM** e un **Transformer Encoder**.

- **Bidirectional LSTM**: Le Reti Neurali Ricorrenti (RNN), introdotte da Elman (1990) [Elm90], sono architetture progettate per modellare dati sequenziali, permettendo di mantenere una "memoria" della sequenza. Tuttavia, le RNN semplici soffrono del problema del "vanishing gradient", che limita la loro capacità di apprendere dipendenze a lungo termine.

Per superare questo limite, la nostra architettura utilizza le **Long Short-Term Memory (LSTM)**, una variante avanzata di RNN introdotta da Hochreiter e Schmidhuber (1997) [HS97]. L'innovazione chiave dell'LSTM è l'introduzione di una "cella di memoria" (c_t) e di tre meccanismi di controllo chiamati "gate" (forget, input, output) che regolano il flusso di informazioni.

Il funzionamento di una cella LSTM a un tempo t è definito dalle seguenti equazioni:

1. **Forget Gate** (f_t): Decide quali informazioni della cella di memoria precedente, c_{t-1} , devono essere "dimenticate".

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f)$$

2. **Input Gate** (i_t): Decide quali nuove informazioni devono essere immagazzinate nella cella. È composto da due parti: la prima decide quali valori aggiornare, la seconda crea un vettore di nuovi candidati $\tilde{c}_t$.

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C)$$

3. **Aggiornamento della Cella di Memoria** (c_t): Lo stato della cella precedente viene aggiornato, dimenticando alcune informazioni e aggiungendone di nuove.

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t$$

4. **Output Gate** (o_t): Decide quale parte dello stato della cella deve essere passata allo stato nascosto successivo, h_t .

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$$

dove σ è la funzione sigmoide e $\odot$ rappresenta la moltiplicazione elemento per elemento (prodotto di Hadamard).

Una LSTM standard processa la sequenza in una sola direzione. Per catturare il contesto sia passato che futuro, la nostra architettura impiega una **BiLSTM**, che consiste di due LSTM separate: una che processa la sequenza dall'inizio alla fine (forward) e una che la processa dalla fine all'inizio (backward).

- **Transformer Encoder:** Il Transformer, introdotto da Vaswani et al. [Ash+17], si basa interamente sul meccanismo di **self-attention** per calcolare le rappresentazioni degli elementi di una sequenza. A differenza delle RNN che processano la sequenza in modo iterativo, il self-attention permette a ogni elemento di interagire direttamente con tutti gli altri, pesando la loro importanza. La formulazione matriciale è:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Il nostro modulo sequenziale utilizza un encoder Transformer standard, composto da più blocchi impilati di self-attention multi-head e layer feed-forward.

3.3.3 Pooling e Classificazione Finale

L'output del modulo sequenziale è una sequenza di vettori $X = (\mathbf{x}_1, \dots, \mathbf{x}_T)$. Per aggregarli in un'unica rappresentazione a dimensione fissa, applichiamo un layer di **Gated Attention Pooling** [ITW18]. Questo meccanismo, più sofisticato di un'attention standard, utilizza un gate per pesare dinamicamente le feature prima di calcolare i pesi di attention, permettendo un controllo più fine su quali informazioni aggregare.

Il processo si articola in due passaggi. Primo, per ogni vettore di input $\mathbf{x}_t$, viene calcolata una rappresentazione intermedia $\mathbf{h}_t$ attraverso un meccanismo di gating:

$$\mathbf{h}_t = \tanh(\mathbf{W}_V \mathbf{x}_t + \mathbf{b}_V) \odot \sigma(\mathbf{W}_U \mathbf{x}_t + \mathbf{b}_U)$$

dove $\mathbf{W}_V$ e $\mathbf{W}_U$ sono matrici di pesi addestrabili, $\odot$ è il prodotto di Hadamard e σ è la funzione sigmoide, che agisce da "gate" per modulare il flusso di informazioni.

Successivamente, i pesi di attention finali α_t vengono calcolati a partire da queste rappresentazioni e utilizzati per produrre il vettore aggregato $\mathbf{c}$:

$$\alpha_t = \frac{\exp(\mathbf{w}^T \mathbf{h}_t)}{\sum_{j=1}^T \exp(\mathbf{w}^T \mathbf{h}_j)} \quad ; \quad \mathbf{c} = \sum_{t=1}^T \alpha_t \mathbf{x}_t$$

dove $\mathbf{w}$ è un altro vettore di pesi addestrabili. Questo permette al modello di focalizzarsi in modo selettivo sui chunk più rilevanti per la diagnosi. Il vettore aggregato $\mathbf{c}$ viene infine passato a un classificatore lineare per produrre la predizione finale.

3.3.4 Strategia Sperimentale

Data la vastità dello spazio di ricerca, che include la scelta del foundation model (Wav2Vec2.0, Hubert, WavLM, etc.), del layer specifico da cui estrarre le feature e dell'architettura sequenziale a valle, abbiamo adottato una strategia sperimentale a due fasi per disaccoppiare le variabili e rendere la ricerca trattabile e rigorosa.

1. Ricerca dell'Architettura Ottimale:

L'obiettivo di questa prima fase è identificare la migliore architettura sequenziale (BiLSTM vs. Transformer) e i suoi iperparametri ottimali (es. dimensione nascosta, learning rate, dropout). Per rendere questa ricerca agnostica rispetto a un singolo layer, abbiamo utilizzato una rappresentazione delle feature unificata e robusta: una **somma pesata con pesi addestrabili di tutti i layer** di un singolo foundation model di riferimento (Wav2Vec2.0-Base). Nello specifico, per ogni segmento, l'embedding di input al modulo sequenziale è calcolato come una somma pesata delle feature estratte da tutti i suoi layer:

$$\mathbf{z}_{\text{pooled}} = \sum_{l=0}^L w_l \cdot \text{LayerNorm}(\mathbf{z}_l)$$

dove $\mathbf{z}_l$ è l'output del layer l e i pesi w_l (normalizzati con softmax) sono parametri addestrabili.

2. Analisi Comparativa dei Modelli e dei Layer:

Una volta ottenuti i migliori iperparametri a valle dalla Fase 1, conduciamo l'esperimento principale: un'analisi comparativa sistematica. Per ciascun foundation model (Wav2Vec2.0, HuBERT, WavLM e Whisper encoder) eseguiamo un processo sistematico di addestramento: per ogni modello, alleniamo un classificatore distinto utilizzando esclusivamente le rappresentazioni fornite da un singolo layer. In altre parole, per Wav2Vec2.0 si addestra un modello basato sulle feature del layer 0, un altro basato sulle feature del layer 1, e così via fino all'ultimo layer; lo stesso approccio viene ripetuto per tutti i foundation model considerati.

Questa strategia consente di valutare in maniera rigorosa quale combinazione di foundation model

e livello di astrazione fornisca le rappresentazioni più informative per il rilevamento della depressione, mantenendo costante l'architettura di clas-

sificazione. I risultati, discussi nel Capitolo 4, rivelano quali siano le feature più discriminanti per il task.

4 Risultati

4.1 Dataset e Pre-elaborazione

Per questo studio, la nostra metodologia si avvale di due corpus di dati che sono diventati lo standard di riferimento per la comunità scientifica internazionale nel campo del rilevamento della depressione: il DAIC-WOZ e la sua estensione, l'eDAIC.

4.1.1 Descrizione del Dataset

Il DAIC-WOZ (Distress Analysis Interview Corpus - Wizard-of-Oz) costituisce il fulcro del nostro lavoro, essendo utilizzato per l'addestramento, la validazione e il test primario dei nostri modelli. Questo dataset in lingua inglese si distingue per la sua metodologia di raccolta unica, basata sul paradigma del "Mago di Oz". Le interviste sono condotte da un agente virtuale animato di nome "Ellie", le cui domande e reazioni sono guidate in tempo reale da un clinico situato in un'altra stanza. Questo setup semi-strutturato permette di ottenere un dialogo naturalistico ma controllato. Il corpus è multimodale e per ogni partecipante fornisce:

1. La registrazione audio completa dell'intervista.
2. La trascrizione testuale del dialogo, arricchita da annotazioni di eventi non verbali.
3. Un punteggio di gravità della depressione ottenuto tramite il Patient Health Questionnaire a 8 item (PHQ-8), un questionario di autovalutazione clinicamente validato [LZC23b].

Il punteggio PHQ-8, che varia da 0 a 24, funge da ground-truth per i nostri esperimenti. Conformemente ai protocolli stabiliti in competizioni scientifiche come l'AVEC (Audio/Visual Emotion Challenge) [Mic+16], il nostro task principale è formalizzato come una classificazione binaria. Un partecipante è assegnato alla classe "depresso" ($y = 1$) se il suo punteggio PHQ-8 è maggiore o uguale a 10 ($PHQ - 8 \geq 10$), e alla classe "non depresso" ($y = 0$) altrimenti.

Il secondo corpus, eDAIC (Extended Distress Analysis Interview Corpus), svolge un ruolo ausiliario nella nostra metodologia. Sebbene sia noto per le sue annotazioni a livello di singolo turno di parola, nel nostro studio viene impiegato in modo mirato come fonte esterna per l'aumento dei dati, al fine di affrontare lo squilibrio tra le classi, come verrà dettagliato successivamente.

4.1.2 Data Cleaning

Per garantire che i nostri modelli apprendano da segnali puliti e consistenti, e per rimuovere potenziali variabili confondenti, è stata implementata una rigorosa pipeline di preprocessing sia per i dati audio che per quelli testuali. L'obiettivo è isolare il più possibile il contributo vocale e linguistico del solo partecipante. Per i corpus vocali e testuali si sono eseguite due flussi lavorativi:

- **Preprocessing del Segnale Audio:**

1. **Isolamento del Parlato:** Il primo passo cruciale è stato separare la voce del partecipante da quella dell'intervistatore virtuale. Poiché la voce di "Ellie" è sintetica e priva di variazioni emotive, la sua inclusione contaminerebbe le feature acustiche, introducendo un forte bias.

2. **Segmentazione a Lunghezza Fissa** I modelli di deep learning richiedono input di dimensioni uniformi. Pertanto, le registrazioni audio pulite, che hanno durate variabili, sono state segmentate in sotto-sequenze di lunghezza fissa, con un grado di sovrapposizione variabile, in base a due strategie:

- **Segmentazione guidata dalla trascrizione:** l'audio viene suddiviso rispettando i confini temporali dei turni di parola, garantendo che ogni segmento contenga solo enunciati consecutivi del partecipante. Per evitare segmenti troppo corti o troppo lunghi, vengono applicati vincoli di durata minima e massima, con eventuale sovrapposizione parziale tra segmenti adiacenti.

- **Segmentazione a finestra scorrevole:** l'audio viene diviso in finestre temporali fisse, indipendentemente dalla struttura della trascrizione. Ogni finestra ha una durata prestabilita e può sovrapporsi alla successiva, così da garantire copertura completa e maggiore ridondanza informativa.

Ogni segmento eredita l'etichetta di depressione dell'intera intervista, generando così un dataset di training notevolmente più grande.

- **Normalizzazione delle Trascrizioni:** I turni di parola di "Ellie" sono stati eliminati dalle trascrizioni.

4.1.3 Data Augmentation e Bilancio delle Classi

Un problema ben documentato nei dataset clinici, incluso il DAIC-WOZ, è lo squilibrio tra le classi, con una prevalenza di campioni appartenenti alla classe non depressa. Questa condizione può indurre i modelli di machine learning a sviluppare un bias verso la classe maggioritaria, portando a scarse performance sulla classe minoritaria (depressa), che è spesso quella di maggiore interesse clinico. Per mitigare questo rischio, abbiamo adottato una strategia di data augmentation mirata ad arricchire la classe depressa. Il processo si articola come segue:

1. **Selezione della Fonte di Augmentation:** Per evitare di aumentare semplicemente le varianti dei campioni già presenti nel set di training, abbiamo attinto a una fonte esterna. Nello specifico, abbiamo isolato tutti i campioni audio appartenenti alla classe depressa ($y = 1$) dal dataset eDAIC. Questo ci ha fornito un insieme di registrazioni $D_{eDAIC,1}$ di nuovi parlanti depressi.
2. **Creazione del Dataset di Training (Augmentation opzionale):** I campioni aggiuntivi $D'_{eDAIC,1}$ non definiscono un nuovo dataset "finale", ma costituiscono un'opzione di *data augmentation* attivabile in fase di addestramento. Se l'augmentation è disattivata, utilizziamo esclusivamente il corpus originale DAIC-WOZ; se è attivata, al set originale aggiungiamo i campioni da eDAIC. Formalmente:

$$\mathcal{D}_{\text{train}} = \begin{cases} \mathcal{D}_{\text{DAIC-WOZ}}, & \text{aug. OFF,} \\ \mathcal{D}_{\text{DAIC-WOZ}} \cup \mathcal{D}'_{eDAIC,1}, & \text{aug. ON.} \end{cases}$$

In tutti i casi, i dati originali rimangono invariati; l'augmentation ne estende soltanto la cardinalità durante il training.

Strategie di Bilanciamento nel Training.

Oltre all'augmentation opzionale, sono state implementate strategie di bilanciamento specifiche durante l'addestramento dei modelli per mitigare ulteriormente il bias verso la classe maggioritaria:

- Per il modello **CNN**, è stata testata una strategia di **undersampling a livello di segmento**. Se attivata, per ogni fold di training, i segmenti della classe maggioritaria vengono campionati casualmente per eguagliare il numero di segmenti della classe minoritaria, creando un training set bilanciato.
- Per il modello **SSL**, è stata impiegata una strategia ibrida più avanzata tramite un *sampler* custom. Il nostro **BalancedParticipantSampler** assicura che **ogni batch** sia bilanciato (50/50) e basa il numero di batch per epoca sulla dimensione della classe **minoritaria**. Questo realizza un efficace oversampling della classe minoritaria e undersampling di quella maggioritaria a livello di epoca, garantendo che il modello veda entrambe le classi con la stessa frequenza durante l'aggiornamento dei gradienti.

4.2 Impostazioni Sperimentali

Tutti gli esperimenti sono stati condotti su una workstation dotata di CPU Intel Xeon w7-3445e 64 GB di RAM. L'addestramento e la valutazione dei modelli sono stati eseguiti utilizzando una GPU NVIDIA RTX 6000 Ada Generation con 48 GB VRAM. L'implementazione è stata sviluppata in Python, facendo uso delle librerie PyTorch, Transformers e Scikit-Learn.

4.2.1 Architettura SVM

Il nostro modello di baseline segue una pipeline tradizionale a tre stadi:

- **Estrazione delle Feature:** In linea con studi classici su patologie vocali come il morbo di Parkinson [NSA21], abbiamo estratto tre set di feature acustiche che catturano diverse dimensioni del parlato, facendo uso del framework di DisVoice:
 1. **Articolazione** [Elk+16]: Caratteristiche che descrivono la chiarezza e la precisione con cui vengono prodotti i suoni.
 2. **Fonazione** [TJR17; Vas+17]: Misure relative alla qualita della sorgente glottale, come jitter e shimmer.
 3. **Prosodia** [Vas+17; Oro+17]: Descrittori legati al ritmo, all'intonazione e all'energia dell'eloquio.
 Questi tre set di feature sono stati utilizzati sia singolarmente sia in combinazione (baseline) per addestrare modelli separati.
- **Preprocessing delle Feature:** I dati sono stati pre-elaborati utilizzando tecniche standard. Un SimpleImputer e stato impiegato per gestire i valori mancanti nel set di feature prosodiche, sostituendoli con la media della colonna. Successivamente, tutti i set di feature sono stati normalizzati tramite StandardScaler, che standardizza

le feature rimuovendo la media e scalando a varianza unitaria.

- **Classificatore:** Il classificatore scelto è una Support Vector Machine (SVM). Abbiamo impiegato due kernel, Linear e Radial Basis Function (RBF), le cui funzioni sono definite rispettivamente come:

$$K(x, x') = x^\top x' + c$$

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

La ricerca degli iperparametri ottimali è stata condotta tramite una grid search su un insieme di valori per C (parametro di regolarizzazione) e γ (parametro del kernel). Durante questa fase, i modelli sono stati valutati sia utilizzando le feature selezionate singolarmente, sia combinando tutte le feature, in modo da analizzare l'impatto delle diverse configurazioni. Per mitigare lo squilibrio tra le classi, è stato utilizzato il parametro `class_weight='balanced'`, che aggiusta i pesi delle classi in modo inversamente proporzionale alla loro frequenza.

4.2.2 Architettura CNN

L'architettura del modello di deep learning end-to-end, denominata CNNMLP, è ispirata a modelli efficaci nel rilevamento di patologie vocali [NSA21]. La rete è composta da:

- **Tre Blocchi Convoluzionali:** Ciascun blocco esegue una sequenza di operazioni: Conv1d per l'estrazione di feature, attivazione ReLU, MaxPool1d per il downsampling spaziale e la riduzione della dimensionalità, Dropout e Batch-Norm1d per la regolarizzazione e la stabilizzazione dell'addestramento. Le dimensioni dei kernel convoluzionali sono decrescenti (64, 32, 16), permettendo alla rete di apprendere feature gerarchiche, dai pattern a basso livello a quelli più astratti.
- **Pooling Globale:** L'output dell'ultimo blocco convoluzionale viene processato da un layer AdaptiveAvgPool1d, che riduce ogni feature map a un singolo valore, rendendo il modello robusto a piccole variazioni nella lunghezza dell'input.
- **Testa di Classificazione (MLP):** Un blocco MLP, composto da layer Linear, attivazioni ReLU e Dropout, riceve le feature estratte e produce il logit di classificazione finale.

4.2.3 Architettura SSL

Il nostro modello più avanzato è un'architettura gerarchica il cui disegno sperimentale è stato articolato in due fasi, come descritto nel Capitolo 3. L'architettura finale, utilizzata per generare i risultati, è composta da:

- **Input Features:** Le feature di input sono embedding a livello di segmento, pre-estratte da un **singolo layer** di un foundation model (es. Wav2Vec2.0, layer 8). I segmenti vengono raggruppati in "chunk" sovrapposti dal data loader.
- **Modellazione Sequenziale:** Ogni chunk (una sequenza di embedding di segmenti) viene processato da un **Transformer Encoder** per modellare le dipendenze contestuali tra i segmenti.
- **Pooling e Classificazione per Chunk:** L'output del Transformer (una sequenza di vettori) viene aggregato in un'unica rappresentazione per l'intero chunk tramite un layer di **Gated Attention Pooling** [ITW18]. Il vettore viene infine passato a un classificatore lineare che produce un logit di predizione per quel chunk.
- **Aggregazione a Livello di Paziente:** Per ottenere una singola diagnosi per l'intero partecipante, le predizioni ottenute per tutti i chunk di quell'intervista vengono aggregate a posteriori. La strategia usata è il **majority voting**.

4.3 Addestramento dei modelli

Per garantire una valutazione robusta e un confronto equo, tutti i modelli sono stati addestrati e ottimizzati seguendo un rigoroso protocollo di **validazione incrociata a 5 fold** (StratifiedGroupKFold). Questo approccio assicura che i campioni appartenenti allo stesso partecipante rimangano sempre nello stesso fold (train o validation), fornendo una stima più realistica della capacità di generalizzazione del modello a nuovi individui.

4.3.1 Modello SVM

La selezione del miglior classificatore SVM è stata condotta attraverso una ricerca a griglia (*grid search*) esaustiva, integrata nel processo di cross-validation. Per ogni fold, è stata eseguita una grid search interna per identificare la combinazione di iperparametri più performante. La ricerca ha esplorato:

- Il **parametro di regolarizzazione C** (da $1e-3$ a 1000).

- Il **coefficiente gamma** per il kernel RBF (da $1e-4$ a 1, più scale e auto).
- La **tipologia di kernel** (linear vs rbf).
item La **gestione del peso delle classi** (class_weight='balanced' vs null).

4.3.2 Modello CNN

Anche per i modelli basati su deep learning, la ricerca degli iperparametri è stata condotta all'interno del framework di cross-validation a 5 fold, attraverso un *Protocollo Comune di Addestramento per Fold*.

Per ogni fold, i modelli sono stati addestrati per un massimo di 20 epoche utilizzando l'ottimizzatore **AdamW** e la funzione di perdita BCEWithLogitsLoss. Per prevenire l'overfitting, è stato implementato un meccanismo di **Early Stopping** che interrompe l'addestramento se l'F1-score sul set di validazione non migliora per 5 epoche consecutive. Il modello salvato per quel fold corrisponde ai pesi che hanno prodotto il più alto F1-score.

Per il nostro secondo modello CNN, la ricerca ha esplorato:

- **Strategia di Segmentazione:** transcript vs fixed_length.
- **Durata Segmento:** 3 vs 5 secondi.
- **Sovrapposizione:** 1.5 vs 2.5 secondi.
- **Learning Rate:** $1e-4$ vs $5e-5$.
- **Dropout Rate:** 0.2 vs 0.3.

4.3.3 Modello SLL

Infine, seguendo l'approccio a due fasi descritto nel Capitolo 3, per il modello SSL la ricerca ha esplorato:

- **Architettura Sequenziale:** transformer.
- **Dimensione Nascosta:** 64 (con 2 teste di attention) vs 128 (con 4 teste).
- **Numero di Layer:** 1 vs 2.
- **Chunking:** Combinazioni di lunghezza (5, 10, 15 segmenti) e sovrapposizione (0, 2, 4 segmenti).
- **Learning Rate:** $5e-5$ vs $1e-5$.
- **Dropout Rate:** 0.1 vs 0.2.

Una volta identificata la migliore architettura e configurazione di iperparametri, si è condotto l'esperimento finale.

Come illustrato nel grafico dei risultati sul dev set (Figura 1), questo "sweep" ha rivelato che la combinazione più performante è risultata essere il modello **Wav2Vec2.0-Base utilizzando le feature estratte dall'ottavo layer**.

4.4 Metriche di Valutazione

Per valutare e confrontare in modo completo e rigoroso le performance dei modelli proposti, è stato utilizzato un insieme standard di metriche di classificazione binaria. La scelta di queste metriche è stata guidata dalla necessità di comprendere non solo l'accuratezza complessiva, ma anche il comportamento del classificatore rispetto a ciascuna classe, un aspetto di particolare importanza in applicazioni mediche dove il costo dei falsi positivi e dei falsi negativi può essere molto diverso.

Per definire formalmente le metriche, introduciamo i quattro possibili esiti di una classificazione binaria:

- **True Positives (TP):** Numero di soggetti depressi correttamente classificati come depressi.
- **True Negatives (TN):** Numero di soggetti sani correttamente classificati come sani.
- **False Positives (FP):** Numero di soggetti sani erroneamente classificati come depressi.
- **False Negatives (FN):** Numero di soggetti depressi erroneamente classificati come sani.

Sulla base di questi valori, le metriche utilizzate sono:

- **Accuracy (Accuratezza):** Rappresenta la proporzione di predizioni corrette sul totale delle predizioni. Sebbene sia una metrica intuitiva, può essere fuorviante in presenza di dataset sbilanciati.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Sensitivity (Sensibilità o Recall):** Misura la capacità del modello di identificare correttamente i soggetti positivi (depressi). È una metrica cruciale in contesti di screening, dove è fondamentale non mancare i casi patologici. È anche nota come True Positive Rate (TPR).

$$\text{Sensitivity} = \text{Recall} = \frac{TP}{TP + FN}$$

- **Specificity (Specificità):** Misura la capacità del modello di identificare correttamente i soggetti negativi (sani). Un'alta specificità indica un basso numero di falsi allarmi. È anche nota come True Negative Rate (TNR).

$$\text{Specificity} = \frac{TN}{TN + FP}$$

- **F1-Score:** È la media armonica di Precision (la proporzione di predizioni positive che erano effettivamente corrette, $\frac{TP}{TP+FP}$) e Recall. L'F1-Score fornisce un singolo valore che bilancia entrambe le metriche ed è particolarmente utile quando le classi sono sbilanciate, poiché penalizza i modelli che eccellono in una metrica a scapito dell'altra.

$$\begin{aligned} \text{F1-Score} &= 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \\ &= \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \end{aligned}$$

- **ROC-AUC (Area Under the Receiver Operating Characteristic Curve):** La curva ROC è un grafico che mostra le performance di un classificatore al variare della soglia di discriminazione. Rappresenta il True Positive Rate (Sensitivity) in funzione del False Positive Rate (1 - Specificity). L'**Area Sotto la Curva (AUC)** quantifica la performance complessiva del modello indipendentemente dalla soglia scelta. Un valore di AUC pari a 1.0 indica un classificatore perfetto, mentre un valore di 0.5 corrisponde a una classificazione casuale. L'AUC è una misura robusta della capacità del modello di distinguere tra le due classi.

4.5 Confronto con Modelli Esistenti

I risultati del nostro modello SVM, presentati in **Tabella 4.0**, stabiliscono una chiara baseline per questo studio. Tra i set di feature analizzati, le caratteristiche **prosodiche** si sono dimostrate le più informative, ottenendo le performance migliori sul test set con un **F1-Score di 0.56** e un'**accuratezza di 0.68**.

Tuttavia, il limite principale di questo modello risiede nel suo trade-off tra sensibilità e specificità. Pur dimostrando un'elevata specificità (buona capacità di riconoscere i soggetti sani), la sua **sensibilità è estremamente bassa** indicando una significativa difficoltà nell'identificare correttamente i casi di depressione. È interessante notare come la combinazione di tutti i set di feature (**combined**) non abbia migliorato, ma anzi peggiorato le performance rispetto all'uso delle sole feature prosodiche, suggerendo che un eccesso di informazioni può introdurre rumore.

Confrontando i nostri risultati con il modello di riferimento [Mic+16], il nostro approccio si dimostra superiore. Il modello di riferimento, pur avendo una recall molto alta, soffre di una precisione estremamente bassa, indicando un forte bias che lo rende praticamente inaffidabile.

In conclusione, il nostro SVM basato sulla prosodia costituisce una baseline valida, ma la sua limitata capacità di individuare i casi positivi ne sottolinea la debolezza clinica e motiva chiaramente la necessità di esplorare architetture più potenti.

Models	Features	Dev Set						Test Set					
		Acc.	Prec.	Sens.	Spec.	F1	ROC	Acc.	Prec.	Sens.	Spec.	F1	ROC
Our	Articulation	0.58	-	0.41	0.56	0.48	0.55	0.51	-	0.35	0.57	0.46	0.45
	Phonation	0.6	-	0.41	0.69	0.55	0.58	0.61	-	0.35	0.72	0.54	0.42
	Prosody	0.68	-	0.25	0.91	0.57	0.63	0.68	-	0.28	0.84	0.56	0.62
	Combined	0.68	-	0.33	0.78	0.55	0.63	0.61	-	0.28	0.75	0.52	0.59
[Mic+16]	COVAREP	-	0.62	0.69	-	0.57	-	-	0.6	0.65	-	0.49	-

Tabella 4.0 - SVM Models

I risultati della nostra architettura CNN, confrontati con modelli di riferimento della letteratura, sono riassunti in **Tabella 4.1**. Questa analisi mostra come l’approccio end-to-end rappresenti un passo avanti rispetto alla pipeline classica, ma evidenzia anche le sfide intrinseche legate all’addestramento di reti profonde in contesti con dati limitati.

La nostra implementazione (Our) ha ottenuto sul test set un’**accuratezza di 0.60** e un F1-Score di 0.51. Un’analisi più approfondita delle metriche rivela un trade-off significativo: il modello raggiunge una **specificità del 0.70**, indicando una discreta capacità di identificare correttamente i soggetti non depressi. Tuttavia, questo risultato è ottenuto a scapito di una **sensibilità molto bassa (0.35)**. Clinicamente, questo significa che il nostro modello non riesce a identificare quasi due terzi dei partecipanti effettivamente depressi, un limite severo per un potenziale strumento di screening. Inoltre, le deviazioni standard relativamente elevate (es. ± 0.23 per la sensibilità) suggeriscono una certa instabilità nel processo di addestramento, un fenomeno comune quando si addestrano reti complesse su dataset di dimensioni contenute.

Il confronto con la letteratura contestualizza ulteriormente queste performance. Il modello di [Ma+16] raggiunge un **F1-Score di 0.61** sul dev set, dimostrando una performance superiore alla nostra. La differenza più notevole risiede nella **Sensibilità (0.77)**, che è marcatamente più alta, indicando che quell’architettura è più efficace nel catturare i pattern vocali associati alla depressione. Questo suggerisce che, pur rimanendo nell’ambito delle CNN supervisionate, scelte architetturali e di addestramento differenti possono portare a un significativo miglioramento nella capacità di rilevare i casi positivi.

Infine, il modello di [JVA23] si afferma come lo stato dell’arte in questo confronto, raggiungendo un **F1-Score di 0.73** sul dev set. Questo risultato, notevolmente superiore a entrambi gli altri modelli, dimostra il pieno potenziale delle architetture convoluzionali quando ottimizzate efficacemente per questo task specifico.

In sintesi, il nostro modello CNN, pur essendo concettualmente più avanzato della SVM, non riesce a superare la performance di una baseline basata su feature prosodiche ben ingegnerizzate, probabilmente a causa della scarsità di dati che ne limita la capacità di generalizzazione. Tuttavia, il confronto con [JVA23] conferma che l’approccio CNN è valido e può raggiungere performance elevate. Questo evidenzia come il principale collo di bottiglia non sia l’architettura in sé, ma la **dipendenza da grandi quantità di dati etichettati**. È proprio questo limite che i modelli basati su Self-Supervised Learning, che analizzeremo di seguito, mirano a superare.

Models	Dev Set						Test Set					
	Acc.	Prec.	Sens.	Spec.	F1	ROC	Acc.	Prec.	Sens.	Spec.	F1	ROC
Our	0.59 $\pm$ 0.047	- -	0.56 $\pm$ 0.29	0.55 $\pm$ 0.21	0.52 $\pm$ 0.04	0.59 $\pm$ 0.02	0.6 $\pm$ 0.101	- -	0.35 $\pm$ 0.23	0.70 $\pm$ 0.21	0.51 $\pm$ 0.07	0.56 $\pm$ 0.02
[Ma+16]	-	0.67	0.77	-	0.61	-	-	-	-	-	-	-
[JVA23]	-	-	-	-	0.73	-	-	-	-	-	-	-

Tabella 4.1 - CNN Models

L'introduzione del nostro modello basato su Self-Supervised Learning (SSL) con Wav2Vec, i cui risultati sono in **Tabella 4.2** ha prodotto risultati complessi. Contrariamente alle aspettative, le performance sul test set **F1-Score di 0.47** non hanno superato quelle della nostra baseline SVM.

Tuttavia, il confronto con la letteratura dimostra in modo inequivocabile il potenziale di questo paradigma. Il modello di [Góm+25] raggiunge un F1-Score superiore (**0.553**) mentre l'architettura WavLM^{AER} [WCC23] definisce il nuovo stato dell'arte, con un **F1-Score medio del 0.720**.

Questo notevole divario prestazionale conferma la nostra tesi principale: sebbene la nostra implementazione iniziale abbia mostrato dei limiti, l'approccio SSL, quando sfrutta *foundation models* più avanzati e architetture ottimizzate, è nettamente superiore a qualsiasi altro metodo. Ciò indica che il Self-Supervised Learning rappresenta la frontiera più promettente per il futuro di questo campo.




Figure 1: Confronto delle performance F1-Macro (media su 5 fold) sui diversi layer Transformer di modelli SSL (HuBERT-Base, Wav2Vec2-Base, WavLM-Base e Whisper-Small). I picchi massimi di performance per ciascun modello sono evidenziati con stelle rosse.

Models	Dev Set						Test Set					
	Acc.	Prec.	Sens.	Spec.	F1	ROC	Acc.	Prec.	Sens.	Spec.	F1	ROC
Our	0.59 ± 0.08	-	0.58 ± 0.21	0.6 ± 0.23	0.56 ± 0.04	0.61 ± 0.01	0.53 ± 0.04	-	0.41 ± 0.27	0.58 ± 0.14	0.47 ± 0.07	0.53 ± 0.05
[Góm+25]	-	-	-	-	0.55 ± 0.06	-	-	-	-	-	-	-
[WCC23]	-	-	-	-	0.72 ± 0.03	-	-	-	-	-	-	-

Our - Wav2vec2.0-base-L8,

[Góm+25] - HuBERT-base-L9,

[WCC23] - WavLM^{AER}-base-L10

Tabella 4.2 - SSL Models

Per validare le nostre scelte architetturali, abbiamo condotto un’ablation study sul nostro modello SSL, i cui risultati sono presentati in **Tabella 4.3**. Questa analisi ha confermato l’importanza di ogni componente chiave del nostro sistema.

1. **Importanza del Bilanciamento dei Dati:** Rimuovendo la nostra strategia di data augmentation (Not Balance Train Set), la **sensibilità del modello crolla a 0.0**. Questo indica che, in condizioni di squilibrio, il classificatore impara a predire unicamente la classe maggioritaria (soggetti sani), diventando clinicamente inutile. La nostra tecnica di augmentation con campioni da E-DAIC (E_DAIC Aug. True) si è quindi dimostrata **assolutamente cruciale** per un apprendimento efficace, portando l’**F1-Score sul test set da 0.47 a 0.53** e sul dev set da 0.56 a 0.62, mostrando il bisogno di più dati per migliorare su questo task.
2. **Ruolo del Pooling Gerarchico:** Sostituire il **Gated Attention Pooling** con un semplice **Mean Pooling** (Pooling Type Mean) causa un significativo calo di performance (F1-Score scende a 0.43). Allo stesso modo, rimuovere completamente il **modello sequenziale** che analizza la sequenza di segmenti (Sequential Model False) porta a un crollo ancora più drastico (F1-Score a 0.35).

Questi risultati dimostrano in modo inequivocabile la validità della nostra **architettura gerarchica**. L’efficacia del modello non deriva da un singolo componente, ma dalla sinergia di un sistema che (a) apprende da dati bilanciati, (b) pesa in modo intelligente le informazioni all’interno dei singoli segmenti vocali e, soprattutto, (c) modella le dipendenze temporali lungo l’intera intervista.

Ablation	Dev Set					Test Set				
	Acc.	Sens.	Spec.	F1	ROC	Acc.	Sens.	Spec.	F1	ROC
Not Balance Train Set	0.65	0.0	0.99	0.39	0.47	0.7	0.0	1.0	0.41	0.53
	± 0.0	± 0.0	$\pm \mathbf{0.0}$	± 0.0	± 0.05	$\pm \mathbf{0.012}$	± 0.0	$\pm \mathbf{0.019}$	± 0.004	± 0.122
E_DAIC Aug. True	0.68	0.48	0.78	0.62	0.73	0.58	0.42	0.64	0.53	0.64
	$\pm \mathbf{0.02}$	$\pm \mathbf{0.18}$	± 0.09	$\pm \mathbf{0.05}$	$\pm \mathbf{0.02}$	± 0.08	± 0.13	± 0.13	$\pm \mathbf{0.07}$	$\pm \mathbf{0.05}$
Pooling Type Mean	0.48	0.39	0.52	0.45	0.48	0.49	0.3	0.57	0.43	0.43
	± 0.08	± 0.19	± 0.09	± 0.08	± 0.108	± 0.06	± 0.1	± 0.11	± 0.04	± 0.08
Sequential Model False	0.52	0.48	0.54	0.37	0.46	0.50	0.47	0.52	0.35	0.58
	± 0.16	± 0.51	± 0.51	± 0.13	± 0.103	± 0.202	$\pm \mathbf{0.504}$	± 0.502	± 0.11	± 0.07

Tabella 4.3 - SSL Ablation

4.6 Disponibilità del codice

A supporto della trasparenza e della riproducibilità di questo lavoro, l’intero codice sorgente utilizzato per gli esperimenti, incluse le implementazioni delle architetture, è stato reso pubblicamente disponibile sul repository GitHub del progetto al seguente indirizzo: https://github.com/A-rgonaut/LM-32_Speech_Analysis_for_Depression_Assessment.

5 Conclusioni

5.1 Interpretazione dei risultati

I risultati sperimentali hanno rivelato una chiara e significativa progressione prestazionale attraverso le tre architetture di modelli investigate, confermando l'evoluzione delle capacità rappresentazionali del machine learning nel dominio del parlato.

- L'approccio basato su **Support Vector Machine (SVM)** con feature ingegnerizzate ha stabilito una solida baseline, ma le sue performance si sono dimostrate, come atteso, le più modeste. Questo risultato sottolinea il limite intrinseco della pipeline tradizionale: la sua efficacia è vincolata a priori dalla qualità e dalla completezza del set di feature predefinito.
- La **Rete Neurale Convolutionale (CNN)** ha mostrato un netto miglioramento rispetto alla SVM. Operando su spettrogrammi, la CNN ha dimostrato di poter apprendere autonomamente feature gerarchiche più ricche e discriminanti. Questo posiziona la CNN come un "ponte evolutivo" cruciale, che supera i limiti dell'ingegneria manuale delle feature, ma che rimane dipendente dalla quantità di dati etichettati disponibili per l'addestramento.
- Il modello basato su **Self-Supervised Learning (SSL)** e architettura Transformer ha raggiunto una superiorità schiacciante, definendo lo stato dell'arte nel nostro setup sperimentale. Questo successo è attribuibile alla sua capacità di sfruttare, tramite il pre-addestramento, vaste quantità di dati vocali non etichettati. Il modello impara le rappresentazioni fondamentali del parlato umano prima ancora di essere specializzato sul task della depressione. Questa strategia di transfer learning si è dimostrata la soluzione più efficace per affrontare il problema della scarsità di dati etichettati, tipico del dominio medicale.

Questa progressione suggerisce una conclusione fondamentale: per compiti complessi come il rilevamento di patologie nel parlato, il collo di bottiglia non è più l'algoritmo di classificazione, ma la ricchezza della rappresentazione dei dati. Il successo dei modelli SSL nel catturare le sfumature di come qualcosa viene detto (la prosodia, il ritmo, la qualità della voce) suggerisce che un approccio parallelo applicato al contenuto semantico di cosa viene detto (il testo) potrebbe fornire insight complementari e potenti.

5.2 Implicazioni Etiche e Cliniche

Sebbene promettenti, i risultati di questo studio devono essere inquadrati in un contesto di rigorosa responsabilità clinica ed etica.

- **Implicazioni Cliniche:** È imperativo sottolineare che un sistema come quello proposto non è uno strumento diagnostico autonomo, ma un sistema di supporto alla decisione clinica. Il suo potenziale risiede nella capacità di agire come:
 1. **Strumento di screening precoce:** per identificare individui a rischio che potrebbero non cercare attivamente aiuto a causa dello stigma.
 2. **Strumento di monitoraggio longitudinale:** per tracciare in modo oggettivo la risposta di un paziente a un trattamento nel tempo, fornendo al clinico dati quantitativi sull'evoluzione dei biomarcatori vocali.
 3. **Strumento per aumentare l'accessibilità:** grazie al basso costo e alla scalabilità, potrebbe essere integrato in piattaforme di telemedicina.
- **Considerazioni Etiche:** L'uso di dati vocali, che sono intrinsecamente personali e identificativi, solleva questioni critiche:
 1. **Privacy e Sicurezza:** È fondamentale garantire l'anonimizzazione dei dati, la conservazione sicura e il consenso informato dei partecipanti.
 2. **Bias Algoritmico:** I modelli addestrati su dataset specifici (come il DAIC-WOZ, prevalentemente in lingua inglese) possono non generalizzare bene a diverse popolazioni, culture, lingue o accenti. L'uso non critico potrebbe perpetuare o amplificare le disparità sanitarie.
 3. **Stigmatizzazione e Auto-diagnosi:** La comunicazione dei risultati di un sistema automatico deve essere gestita con estrema cautela per evitare di generare ansia o di incoraggiare l'auto-diagnosi errata.

5.3 Punti di forza

Questo studio presenta diversi punti di forza metodologici, ma è anche soggetto a limitazioni che ne definiscono il perimetro e aprono la strada a future ricerche.

1. **Analisi Comparativa Sistemica:** A differenza di molti studi che propongono un singolo modello, il nostro lavoro confronta tre paradigmi metodologici distinti (classico, supervisionato, SSL) sullo stesso dataset e con lo stesso protocollo di valutazione, fornendo una chiara visione dell'evoluzione del campo.
2. **Utilizzo di Tecniche allo Stato dell'Arte:** L'implementazione di un modello basato su SSL affronta direttamente la sfida più critica del settore: la scarsità di dati etichettati.
3. **Proposta di Architettura Gerarchica:** Il nostro modello SSL è stato progettato per catturare le dipendenze a diverse scale temporali, allineandosi concettualmente alla natura multi-livello dei sintomi vocali.

5.4 Limiti e Lavori Futuri

1. **Generalizzabilità del Dataset:** I modelli sono stati addestrati e valutati principalmente sul cor-

pus DAIC-WOZ, il che limita la generalizzabilità dei risultati ad altre lingue e contesti culturali.

2. **Natura Unimodale dell'Analisi:** La limitazione più significativa del nostro studio è il suo focus esclusivo sulla modalità audio. Analizzando solo il parlato, abbiamo ignorato il ricco contenuto semantico e lessicale presente nelle trascrizioni testuali. Le parole usate da un individuo, la coerenza del suo discorso e la ricchezza del suo vocabolario sono potenti indicatori del suo stato mentale.

Questa limitazione costituisce la principale motivazione per il nostro lavoro futuro. Proponiamo di sviluppare un sistema multimodale che integri l'analisi del segnale vocale con l'analisi del linguaggio naturale (NLP) del testo. Sfruttando architetture Transformer pre-addestrate sia per il parlato (come Wav2vec 2.0) che per il testo (come BERT), intendiamo creare un modello di fusione che possa apprendere in modo sinergico sia dal "come" (audio) sia dal "cosa" (testo) viene detto, con l'obiettivo di ottenere un sistema di rilevamento della depressione più robusto, accurato e clinicamente significativo.

6 Bibliografia

- [Wai+89] A. Waibel et al. “Phoneme Recognition Using Time-Delay Neural Networks”. In: *IEEE Transactions on Acoustics, Speech, and Signal Processing* (1989), pp. 328–339. DOI: 10.1109/29.21701.
- [Elm90] Jeffrey L. Elman. “Finding Structure in Time”. In: *Cognitive Science* (1990), pp. 179–211. DOI: 10.1207/s15516709cog1402_1.
- [CV95] Corinna Cortes and Vladimir Vapnik. “Support-Vector Networks”. In: *Bell Labs* (1995), pp. 273–297. DOI: 10.1023/A:1022627411411.
- [HS97] Sepp Hochreiter and Jürgen Schmidhuber. “Long Short-Term Memory”. In: *Neural Computation* (1997), pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.
- [Lec+98] Y. Lecuna et al. “Gradient-Based Learning Applied to Document Recognition”. In: *Proceedings of the IEEE* (1998), pp. 2278–2324. DOI: 10.1109/5.726791.
- [KZ12] Iyer Ksithija and Khan Zaved. “Depression – A Review”. In: *Signal Transduct Target Ther* (2012), p. 10. DOI: <https://www.researchgate.net/publication/273769453>.
- [M+12] Marcus M. et al. “Depression: A global public health concern”. In: *World Health Organization Paper on Depression* (2012), p. 4. DOI: 10.1037/E517532013-004.
- [Kim14] Yoon Kim. “Convolutional Neural Networks for Sentence Classification”. In: *Arxiv* (2014), p. 6. DOI: 1408.5882.
- [Yan+15] Longfei Yanga et al. “The Effects of Psychological Stress on Depression”. In: *Curr Neuropsychopharmacol* (2015), p. 11. DOI: 10.2174/1570159X1304150831150507.
- [Elk+16] Belalcazar Elkin et al. “Glottal Flow Patterns Analyses for Parkinson’s Disease Detection: Acoustic and Nonlinear Approaches”. In: (2016), pp. 400–407. DOI: 10.1007/978-3-319-45510-5_46.
- [Ma+16] Xingchen Ma et al. “DepAudioNet: An Efficient Deep Model for Audio based Depression Classification”. In: *Proceedings of the 6th International Workshop on Audio/Visual Emotion Challenge* (2016), pp. 35–42. DOI: 10.1145/2988257.2988267.
- [Mic+16] Valstar Michel et al. “AVEC 2016: Depression, Mood, and Emotion Recognition Workshop and Challenge”. In: (2016), p. 8. DOI: 10.1145/2988257.2988258.
- [Ash+17] Vaswani Ashish et al. “Attention Is All You Need”. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems* (2017), pp. 6000–6010. DOI: 10.5555/3295222.3295349.
- [Oro+17] J.R. Orozco-Arroyave et al. “NeuroSpeech: An open-source software for Parkinson’s speech analysis”. In: *Digital Signal Processing* (2017), pp. 207–221. DOI: 10.1016/j.dsp.2017.07.004.
- [TJR17] Arias-Vergara Tomás, Vasquez Juan, and Orozco Juan Rafael. “Parkinson’s Disease and Aging: Analysis of Their Effect in Phonation and Articulation of Speech”. In: *Cognitive Computation* (2017), pp. 1–18. DOI: 10.1007/s12559-017-9497-x.
- [Vás+17] J.C. Vásquez-Correa et al. “Towards an automatic evaluation of the dysarthria level of patients with Parkinson’s disease”. In: *J Commun Disord* (2017), pp. 21–36. DOI: 10.1016/j.jcomdis.2018.08.002.
- [ITW18] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. “Attention-based Deep Multiple Instance Learning”. In: (2018), p. 16. DOI: 1802.04712.
- [Ale+20] Baevski Alexei et al. “wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations”. In: *Proceedings of the 34th International Conference on Neural Information Processing Systems* (2020), p. 12. DOI: 10.5555/3495724.3496768.
- [Hsu+21] Wei-Ning Hsu et al. “HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units”. In: (2021), p. 10. DOI: 2106.07447.

- [NSA21] N. P. Narendra, Björn Schuller, and Paavo Alku. “The Detection of Parkinson’s Disease From Speech Using Voice Source Informations”. In: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 29 (2021), pp. 1925–1936. DOI: 10.1109/TASLP.2021.3078364.
- [RMT21] Olivia Remes, João Francisco Mendes, and Peter Templeton. “Biological, Psychological, and Social Determinants of Depression: A Review of Recent Literature”. In: *Brain Sci.* (2021), p. 33. DOI: 10.3390/brainsci11121633.
- [Che+22] Sanyuan Chen et al. “WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing”. In: (2022), p. 14. DOI: 2110.13900.
- [Mon+22] Joanna Moncrieff et al. “The serotonin theory of depression: a systematic umbrella review of the evidence”. In: *Molecular Psychiatry* (2022), pages 3243–3256. DOI: 10.1038/s41380-022-01661-0.
- [MH22] Scott M. Monroe and Kate L. Harkness. “Major Depression and Its Recurrences: Life Course Matters”. In: *Annu Rev Clin Psychol.* (2022), p. 29. DOI: 10.1146/annurev-clinpsy-072220-021440.
- [Rad+22] Alec Radford et al. “Robust Speech Recognition via Large-Scale Weak Supervision”. In: (2022), p. 28. DOI: 2212.04356.
- [Cor23] William Coryell. “Disturbi depressivi”. In: *Manuali MSD Edizione Professionisti* (2023), p. 16. DOI: <https://www.msdmanuals.com/it/professionale/disturbi-psichiatrici/disturbi-dell-umore/disturbi-depressivi>.
- [JVA23] Wang J, Ravi V, and Alwan A. “Non-uniform Speaker Disentanglement For Depression Detection From Raw Speech Signals”. In: *Interspeech 2023* (2023), pp. 2343–2347. DOI: 10.21437/interspeech.2023-2101.
- [LZC23a] Clinton Lau, Xiaodan Zhu, and Wai-Yip Chan. “Automatic depression severity assessment with deep learning using parameter-efficient tuning”. In: *Front Psychiatry* (2023), p. 14. DOI: 10.3389/fpsy.2023.1160291.
- [LZC23b] Clinton Lau, Xiaodan Zhu, and Wai-Yip Chan. “Automatic depression severity assessment with deep learning using parameter-efficient tuning”. In: (2023), p. 14. DOI: 10.3389/fpsy.2023.1160291.
- [Nic+23] David Nickson et al. “Prediction and diagnosis of depression using machine learning with electronic health records data: a systematic review”. In: *BMC Med Inform Decis Mak* (2023), p. 38. DOI: 10.1186/s12911-023-02341-x.
- [PH23] Chand S. P. and Arif H. *Depression*. 2023. URL: <https://www.ncbi.nlm.nih.gov/books/NBK430847/>.
- [WCC23] Wu Wen, Zhang Chao, and Woodland Philip C. “Self-Supervised Representations in Speech-Based Depression Detections”. In: (2023), pp. 1–15. DOI: 10.1109/ICASSP49357.2023.10094910.
- [Cui+24] Lulu Cui et al. “Major depressive disorder: hypothesis, mechanism, prevention and treatment”. In: *Signal Transduct Target Ther* (2024), p. 32. DOI: 10.1038/s41392-024-01738-y.
- [Qua+24] Moreno La Quatra et al. “Exploiting Foundation Models and Enhancement for Parkinson’s Disease Detection from Speech in Real-World Operative Conditions”. In: *Interspeech 2024* (2024), p. 5. DOI: 10.21437/Interspeech.2024-522.
- [Zha+24] Xu Zhang et al. “Improving speech depression detection using transfer learning with wav2vec 2.0 in low-resource environments”. In: *Sci Rep.* (2024), p. 14. DOI: <https://doi.org/10.1038/s41598-024-60278-1>.
- [Góm+25] Lucía Gómez-Zaragozá et al. “Speech and Text Foundation Models for Depression Detection: Cross-Task and Cross-Language Evaluation”. In: *Interspeech 2025* (2025), pp. 5253–5257. DOI: 10.21437/Interspeech.2025-1035.